Sprawozdanie z projektu - symulator tomografu komputerowego

1 Skład grupy

- Zuzanna Piniarska 136782
- Mateusz Kałamoniak 136730

2 Opis projektu

2.1 Zastosowany model tomografu: równoległy

2.2 Zastosowany jezyk programowania i biblioteki

Jezyk: **Python3**

Biblioteki:

1. skimage
2. numpy
3. PIL
4. sklearn
5. scipy
6. pydicom
7. matplotlib

2.3 Główne funkcje programu

2.3.1 Pozyskiwanie odczytów dla poszczególnych detektorów

```
def transform(self, image):
    sinogram = np.zeros((self.steps, self.detectors), dtype='float64')
    self.get_circle(image)
    x, y = image.shape
    x_circle, y_circle, r_circle = self.circle
    for s in range(self.steps):
        for d in range(self.detectors):
            x1 = r_circle * np.cos(np.deg2rad(s + (self.l_angle / 2)
            - d * (self.l_angle / (self.detectors - 1))))
            y1 = r_circle * np.sin(np.deg2rad(s + (self.l_angle / 2)
            - d * (self.l_angle / (self.detectors - 1))))
            x1 = int(x1) + (x // 2)
            y1 = int(y1) + (y // 2)

            x2 = r_circle * np.cos(
                np.deg2rad(s + 180 - (self.l_angle / 2)
                + d * (self.l_angle / (self.detectors - 1))))
            y2 = r_circle * np.sin(
                np.deg2rad(s + 180 - (self.l_angle / 2)
                + d * (self.l_angle / (self.detectors - 1))))
            x2 = int(x2) + (x // 2)
            y2 = int(y2) + (y // 2)

            xx, yy = RadonTransform.bresenham(x1, x2, y1, y2)
            sinogram[s, d] = sum(image[xx, yy])
    return sinogram
```

2.3.2 Filtrowanie sinogramu

```
def get_mask(self):
    mask_size = int(np.floor(self.detectors / 2))
    mask = np.zeros(mask_size)
    mask_center = int(np.floor(mask_size / 2))
    for i in range(mask_size):
        j = i - mask_center
        if j % 2 != 0:
            mask[i] = (-4 / np.pi ** 2) / (j ** 2)
    mask[mask_center] = 1
```

```
    return mask



def filtering(self, image):
    filtered = np.zeros((self.steps, self.detectors))
    mask = self.get_mask()

    for step in range(self.steps):
        filtered[step] = signal.convolve(image[step], mask,
        mode='same', method='direct')
    return filtered
```

2.3.3 Normalizacja obrazu

```
def normalize_pixels(self, image, pixels, size):
    for x in range(size):
        for y in range(size):
            if pixels[x, y] > 0:
                image[x, y] = image[x, y] / pixels[x, y]
    return image
```

2.3.4 Obliczanie RMSE

```
def RMSE(image, inversed_image):
    image = image.copy()
    inversed_image = inversed_image.copy()
    x, y = image.shape
    for i in range(x):
        for j in range(y):
            image[i][j] /= 255
            inversed_image[i][j] /= 255
    return metrics.mean_squared_error(image, inversed_image,
    multioutput='uniform_average', squared=False)
```

2.3.5 Odczyt i zapis w formacie DICOM

```
     @staticmethod
    def read_dicom(file):
        dataset = dicom.dcmread(file)
        print(file)
        print(dataset.PatientName)
```

```
        print(dataset.StudyDate)
        print(dataset.ImageComments)

    @staticmethod
    def write_dicom(file, filename, name, date, comments):
        ds = pydicom.dcmread(filename)
        ds.PatientName = name
        ds.StudyDate = date
        ds.ImageComments = comments
        ds.PixelData = file.tobytes()
        ds.Rows = file.shape[0]
        ds.Columns = file.shape[1]
        ds.save_as(filename)
        print('DICOM file saved')
```

2.4 Wyniki eksperymentu

W przypadku eksperymentu ze zmienna ilościa iteracji wykonywania transformaty radona, wieksza liczba kroków znacznie wpływała na dokładność obrazu. Według mnie najlepsza czytelność została osiagnieta dla 6. obserwacji - dla wartości 540. Wartość RMSE wynosi wtedy 2,15. Najniższa uzyskana wartość RMSE to 2,10 jednak te obrazy nieznacznie sie wzgledem siebie różnia. Można śmiało stwierdzić jednak, że zbyt mała ilość iteracji przy wykonywaniu algorytmu jest szkodliwa dla uzyskanego obrazu i nie należy wykonywać mniej niż 360 kroków.
Dla parametru rozpietości katowej optymalna wartość błedu średniokwadratowego jest osiagana dla 90 stopni. Wieksze wartości prowadza do wyższej wartości błedu ze wzgledu na zbyt szeroki kat co prowadzi do powstawania widocznych linii na przetworzonym obrazie
Wraz ze wzrostem ilości detektorów bład średniokwadratowy ciagle maleje. Dla 180 detektorów wynik działania transformaty jest dobra aproksymacja oryginalnego obrazu. Od około 270 detektorów zmiana wizualna jest nieznaczaca. Rośnie za to czas wykonywania obliczeń, dlatego ilość detektorów równa 180 lub 270 można uznać za optymalna.
Poniżej znajduja sie wykresy wizualizujace wyniki eksperymentu.

Wykonany został też eksperyment, w którym dla takich samych parametrów wykonano obraz z oraz bez filtrowania sinogramu. Obraz bez filtrowania wyglada znacznie gorzej a wartość RMSE wynosi aż 83.76277468645526. Nie jest to korzystny wynik. Zastosowanie filtra przy tych samych parametrach dało błąd średniokwadratowy równy 1.5092168255763534 - znacznie lepszy wynik. Eksperyment dowodzi tego, że filtrowanie sinogramu jest konieczna operacja przy wykonywaniu obliczeń. Jego brak bardzo pogorszył jakość końcowego efektu przetwarzania.

Poniżej znajduja sie zdjecia finalnych obrazów z filtrem oraz bez filtra na sinogramie.

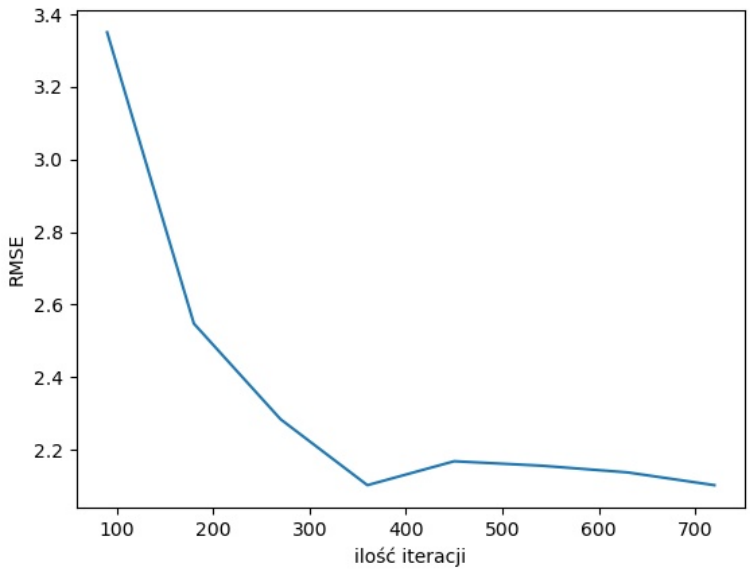

Rysunek 1: Wykres RMSE ze zmiana ilości kroków

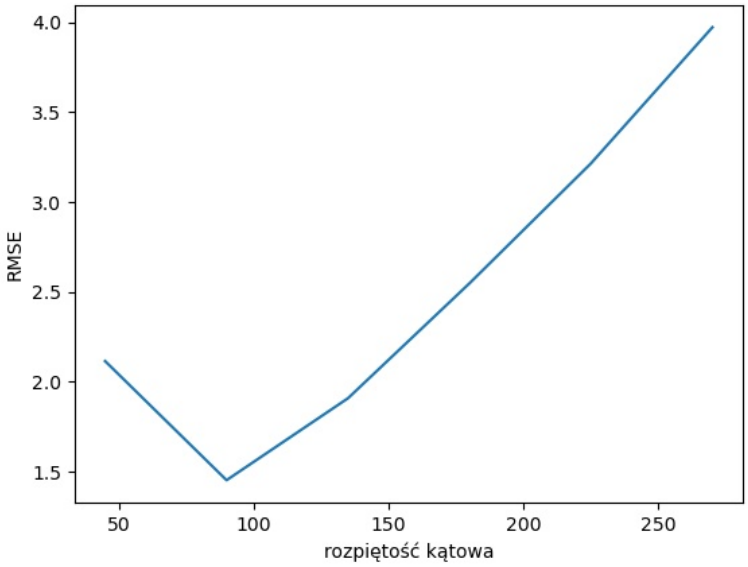

Rysunek 2: Wykres RMSE ze zmiana rozpietości katowej

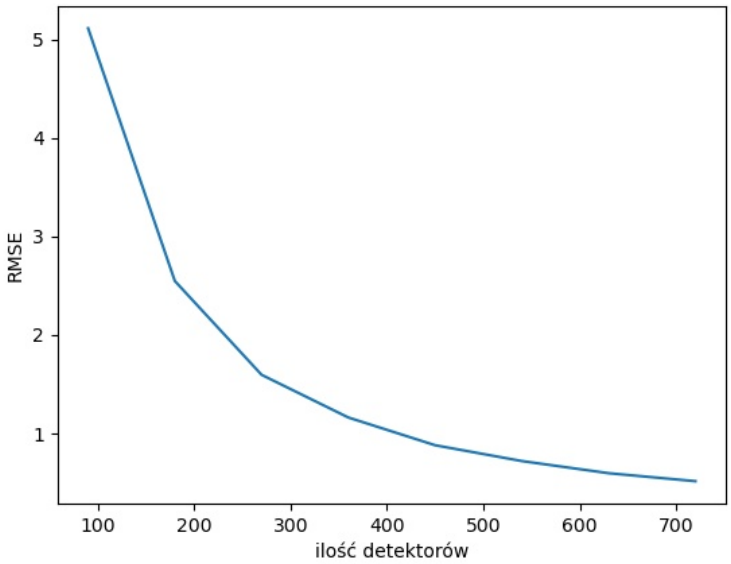

Rysunek 3: Wykres RMSE ze zmiana ilości detektorów

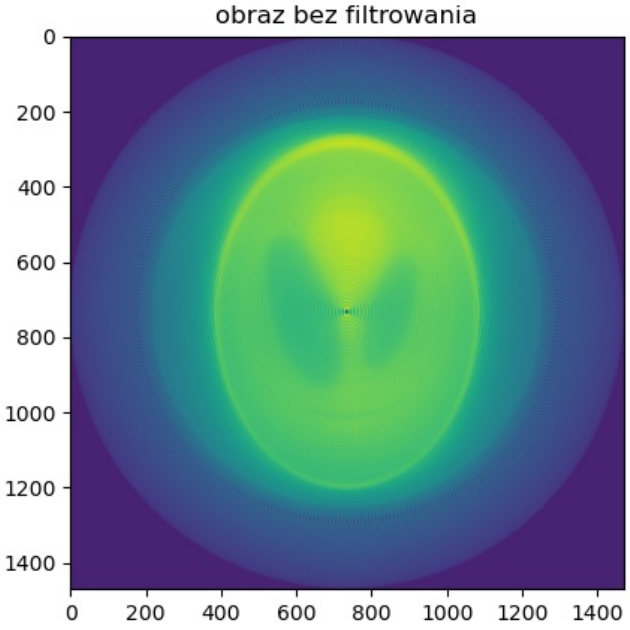
obraz bez filtrowania
0
200
400
600
800
1000
1200
1400

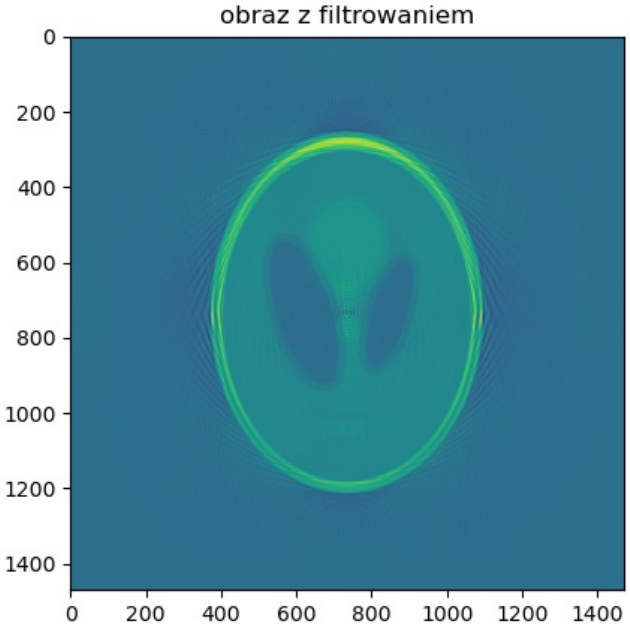
obraz z filtrowaniem
0
200
400
600
800
1000
1200
1400